

Nome	O que é	Exemplo	Quando usar	Risco principal	Hack
Context Dump	Colar todo conteúdo no prompt	Manual de RH com 150 páginas	Bases pequenas (até ~300 páginas)	Custo alto, limite de tokens	Criar cheat sheets para
Prompt Caching	Reaproveitar cache do modelo	Equipe de suporte com perguntas repetidas	Consultas em curto período	Depende da janela de cache	Agrupar perguntas no
Chunking	Selecionar apenas trechos relevantes	Wiki de 500 páginas organizada	Bases organizadas (RH, TI, Finanças)	Erro se pergunta cruzar áreas	Usar tags/metadados
RAG Tradicional	Embeddings + banco vetorial	50 mil PDFs de atendimento	Grandes volumes (milhares de docs)	Ruído e tuning complexo	Adicionar metadados
Hybrid RAG	Combinar busca semântica + palavra-chave	Diagnóstico de código de erro P0420	Domínios técnicos, jurídico, médico	Manutenção dupla (vetor + keywords)	Usar keyword co
Contextual RAG	Trecho + contexto antes/depois	Procedimento médico em 5 passos	Manuais, receitas, contratos	Mais tokens, risco de extrapolar limite	Ajustar janelas dinâm
Agentic RAG	Agente controla/refina a busca	Help desk com pergunta vaga	Perguntas vagas, pesquisa complexa	Custo alto e risco de loop	Limite de passos
Multi-index RAG	Índices especializados conectados	Logs + agenda de deploys + tickets	Empresas com dados heterogêneos	Complexidade e manutenção pesada	Padronizar metadado
Knowledge Graph RAG	Mapeia entidades e relações (grafo)	Supply chain com cliente-produto-engenheiro	Supply chain, visão 360° clientes	Atualização trabalhosa, erros em cascata	Começar com subg
Dynamic Graph RAG	Rede de agentes que mantém relações vivas	Varejo grande com vínculos dinâmicos	Fortune 500, pesquisa em larga escala	Custo alto, conflitos entre agentes	Mediação, auditor